

Priorización de contactos en campañas telefónicas: predicción de suscripción a plazo fijo

Diplomado en Ciencia de Datos y Análisis Avanzado - Unidad N.º 9, Proyecto Final Integrador

Equipo N.º X - Integrantes: Apellido, Nombre; Apellido, Nombre; Apellido, Nombre -
Fecha: __ / __ / 2026

1. Resumen ejecutivo

Banco del Plata (empresa hipotética) ofrece plazos fijos por telemarketing. El call center solo puede llamar a cerca del **30 % de la cartera** por campaña y hoy la lista se disca sin priorizar: la conversión histórica es de 11,3 %, por lo que la mayoría de las llamadas no termina en suscripción.

Qué proponemos. Un modelo que estime, antes de llamar, la propensión a suscribir y ordene la lista de mayor a menor. **Audiencia:** gerencia de Marketing Directo y jefatura del call center (interna); el cliente no interactúa con el modelo. **KPI de impacto:** Recall @ top 30 % (proporción de las suscripciones capturadas llamando solo al 30 % mejor rankeado) y, como resultado de negocio, costo por suscripción.

2. Definición del problema y caso de negocio

Objetivo medible. Capturar al menos el **70 % de las suscripciones contactando como máximo al 30 % de la base**, medido sobre un test que no interviene en la selección del modelo.

Hipótesis. H1: el historial de campañas previas (poutcome, pdays, previous) aporta señal. H2: el mes de contacto modifica la propensión. H3: más contactos en la misma campaña muestran rendimientos decrecientes.

Restricciones. Operativa: el producto es un ranking con cupo de 30 %. Temporal: el score se calcula antes de la llamada; toda variable conocida después queda excluida. Ética: edad y estado civil se tratan como atributos sensibles a auditar; no hay identificadores personales. Técnica: ejecución local o en Colab gratuito.

Valor esperado. Campaña de referencia: 41.000 clientes, USD 1,20 por llamada. Sin ranking, capturar el 70 % de las suscripciones exige llamar a ~70 % de la cartera; con el modelo, al 30 %. Se evitarían 16.400 llamadas: **ahorro bruto potencial de USD 19.680 por campaña**, a validar en la entrega final junto con costos de implementación.

3. Relevamiento de fuentes de datos

Fuente y licencia. Bank Marketing, UCI Machine Learning Repository (Moro, Rita y Cortez, 2014), licencia CC BY 4.0. **Fuente oficial:** <https://archive.ics.uci.edu/dataset/222/bank+marketing>. **DOI:** <https://doi.org/10.24432/C5K306>. **Archivo:** bank-additional-full.csv, con 41.188 registros, 20

variables de entrada más la variable objetivo, ordenado cronológicamente de mayo de 2008 a noviembre de 2010. El notebook descarga el zip oficial, recorre sus zips anidados y valida el esquema para evitar mezclarlo con otras variantes.

Variable	Tipo	Descripción	Rol
age	Entero	Edad del cliente	Predictora / auditar
job	Categoría	Ocupación	Predictora
marital	Categoría	Estado civil	Predictora / auditar
default	Categoría	Crédito en mora	Predictora
contact	Categoría	Canal: celular o fijo	Predictora
month	Categoría	Mes del último contacto	Predictora (H2)
campaign	Entero	Contactos en la campaña actual	Predictora (H3)
pdays	Entero	Días desde contacto previo (999 = nunca)	Predictora (H1)
poutcome	Categoría	Resultado de la campaña anterior	Predictora (H1)
euribor3m	Continua	Tasa Euribor 3 meses (contexto macro)	Predictora / drift
y	Binaria	Suscribió el plazo fijo	Objetivo
duration	Entero	Duración de la llamada	Excluida (fuga)

Tabla 1. Diccionario mínimo (10 variables principales + objetivo + variable excluida).

Calidad de los datos (medida sobre el archivo completo)

Aspecto	Evidencia	Tratamiento
Nulos explícitos	0 en todas las variables	No requiere imputación
unknown en default	8.597 (20,9 %); solo 3 casos 'yes'	Categoría explícita
unknown en education	1.731 (4,2 %)	Categoría explícita
unknown en housing / loan	990 cada una (2,4 %)	Categoría explícita
unknown en job / marital	330 / 80	Categoría explícita
Duplicados exactos	12 filas	Eliminar (ya reportado)
Centinela pdays = 999	96,3 % nunca contactado	Bandera + días (0 si nunca)
Outliers de campaign	Máx. 56; 869 casos con más de 10 (2,1 %)	Legítimos: no se eliminan
Desbalance	Clase positiva 11,27 %	Accuracy no es criterio
Cambio temporal	Prevalencia por décimo del archivo: de 2,8 % a 45,9 %	Validación temporal

Tabla 2. Nulos, categorías unknown, duplicados, centinelas y outliers.

Evidencia mínima para las hipótesis. H1: poutcome = success convierte 65,1 % frente a 8,8 % sin campaña previa. H2: mayo concentra 13.769 contactos con 6,4 %, mientras marzo, septiembre, octubre y diciembre superan 40 % con poco volumen. H3: la conversión cae de 13,0 % con un contacto a 3,1 % con más de diez. Son asociaciones descriptivas, no causales.

Decisiones de limpieza ya tomadas	Decisiones pendientes
Excluir duration: solo se conoce después del contacto (fuga).	Evaluar tope o transformación de campaign según su efecto en métricas.
Conservar unknown como categoría explícita.	Evaluar agrupar niveles poco frecuentes de job y education.
pdays = 999 → contactado_antes y dias_desde_contacto.	Evaluar ponderación de clases solo si mejora el ranking. Si el score se usará como probabilidad absoluta, evaluar calibración.
Eliminar los 12 duplicados exactos.	Evaluar codificación de month (categoría o cíclica).
Usar solo bank-additional-full.csv (orden temporal).	Definir cómo tratar la dependencia de variables macroeconómicas.

4. Plan de modelado y validación

Metodología. CRISP-DM: las secciones 1-2 cubren la comprensión del negocio y la 3, la comprensión y el inicio de la preparación de datos. Las decisiones se registran en `data_log.md`. Toda transformación aprendida se encapsula en un Pipeline de scikit-learn para evitar fuga entre particiones.

Algoritmos. Regresión logística (referencia interpretable), Random Forest y XGBoost.

Esquema de validación. (a) Holdout estratificado 80/20: el 20 % de test no se usa para elegir. (b) Validación cruzada estratificada de 5 folds sobre el 80 % de desarrollo. (c) Validación temporal: entrenar con el primer 80 % del archivo y evaluar en el último 20 %; una partición interna 60 %/20 % se reserva para desempates. **Regla de selección ex ante:** los modelos a menos de un desvío de la mejor PR-AUC en CV se consideran empatados; si la logística empatara, se elige la logística; si no, se usa la validación temporal interna como desempate. Si todos quedan cerca del piso temporal, el desempate se considera débil y el elegido queda solo como candidato provisional.

Métrica	Por qué
Recall @ top 30 %	Principal de negocio: traduce la meta operativa.
PR-AUC	Principal estadística: calidad del ranking con clase minoritaria.
Precision, Lift @ 30 % y lift por deciles	Cuánto mejora el ranking frente a una selección aleatoria.
ROC-AUC, F1 y accuracy de la regla top 30 %	Complementarias; accuracy no gobierna la decisión.

Baselines reproducibles (random_state=42, mismo test estratificado). El clasificador de clase mayoritaria sirve como piso de clasificación: PR-AUC = prevalencia ($\approx 0,113$), ROC-AUC = 0,50 y accuracy $\approx 88,7$ %, pero **no define un ranking**, por lo que Recall @ 30 % no corresponde. El benchmark operativo es el ranking aleatorio: PR-AUC $\approx 0,117$ y Recall @ 30 % $\approx 30,4$ %. Primer modelo de referencia (logística, CV 5 folds): PR-AUC $0,451 \pm 0,014$ y Recall @ 30 % 70,0 %. El enfoque es viable.

Referencia	Valor	Criterio
Benchmark aleatorio	Recall @ 30 % ≈ 30 %	Piso: igualarlo no agrega valor.
Umbral mínimo de éxito	Recall @ 30 % ≥ 60 %	Duplica el ranking aleatorio.
Objetivo comprometido	Recall @ 30 % ≥ 70 %	Meta de la sección 2.

Riesgos, limitaciones y próximos pasos

- **Cambio de régimen:** la prevalencia crece a lo largo del archivo (2,8 % $\rightarrow$ 45,9 %); un split aleatorio puede sobreestimar el desempeño futuro.
- **Contexto:** datos de un banco portugués 2008-2010; el proyecto demuestra el método, no una política comercial vigente en Argentina.
- **Fuga y sesgo:** duration excluida; se auditará la selección por franja etaria y estado civil.
- **Próximos pasos:** (1) cerrar decisiones pendientes; (2) CV y selección; (3) test estable y temporal; (4) SHAP y ablaciones de H1-H3; (5) revisar calibración si se pretende interpretar el score como probabilidad absoluta; (6) cuantificar impacto y riesgos.

Repositorio público (notebook, requirements.txt, data_log.md y README): [URL del repositorio del equipo]. Checklist de la consigna: problema medible, KPI, fuentes y licencia, 10 variables, nulos y outliers con cifras, limpieza tomada vs. pendiente, baseline reproducible, métricas y validación definidas antes del modelado, umbral y benchmark, riesgos.